# 从 API 开始理解 QNX

2009-05-25

个人来讲,喜欢通过 API 来理解一个系统。所以这篇文章也直接从讲解 API 开始。文章的对象是那些对微内核的结构有些了解后,而想实实在在的编些程序的年轻 IT 民工们。

如果你的实际工作是在 QNX 上编程的话,刚开头的这部份,可能还不能立刻派上用场。不过,理解这部份知识,对于将来理解更上层的 API 会有很大的帮助;而且,有兴趣的同学,也可以从这里管中窥豹地看一看 QNX 是如何做到"商用微内核"系统的。

# 消息传递

大家都知道 QNX 是个基于微内核结构的操作系统,靠的是进程间通讯来实现整个系统功能的。整个 QNX 上的服务,基本上都是服务器进程与客户端进程的通信来完成的。当然很多时候,一个进程既是服务器,也是客户端。

那么具体到写一个程序的时候,到底这个通讯是如何完成的呢?这章就是具体介绐最底层的消息传递 API的。

消息传递是通过内核进行的,所以所谓的 API,实际也就是最底层的内核调用了。需要再次指出的是,真正在 QNX 上写程序的时候,很少会直接用到这些 API,而是利用更高层的 API,不过,知道这些底层的 API对于将来理解建立在这些 API 上的界面,应该会有帮助的。下面讲解中,也会穿插一些实际的例子。

# 频道 (Channel) 与连接 (Connect)

消息传递是基于服务器与客户端的模式来进行的,那么客户端怎样才能与服务器端通讯呢?最简单的,当然是指定对方的进程号。要发送的一方,将消息加一个头,告诉内核"把这个消息发给进程号为 12345 的进程"就行了。

但是 QNX 完整支持 POSIX 线程后,这种方法会有问题的。想一想,如果服务器有两个线程,同时提供两个不同的服务,那客户端要怎么发送给特定的服务呢?或者你会说"把这个消息发给进程 12345 的线程 3"就

行了。可是,如果某一个服务,不是由单一线程来进行服务的,而是有一组线程进行的,那又怎么办呢?

为此,QNX 抽象出了"频道"(Channel)这个概念。一个频道,就是一个服务的入口;至于这个频道到底具体有多少线程为其服务,那都是服务器端自己的事情。一个服务器如果有多个服务,它也可以开多个频道。这个概念还是比较好理解的,拿 Socket 编程来比方,"频道"就有点像端口号,一个端口号对应了一个服务。可以用多个线程 listen()在同一个端口上,并发处理服务。

而客户端,在向特定"频道"发送消息前,需要先建立连接(Connection),然后将消息在连接上发出去。 这样同一个客户端,如果需要,可以与同一个频道建立多个连接。这个过程,有 Socket 编程经验的同学应该不难理解。

所以,大致上通讯的准备过程是这样的:

#### 服务器

ChannelId = ChannelCreate(Flags);

#### 客户端

ConnectionId = ConnectAttach(Node, Pid, Chid, Index, Flag);

服务器端就不用解释了,客户端要建立连接的话,它需要 Node,这个就是机器号。如果过 QNX 的 QNET 网络(透明分布处理)进行消息传递时,这个值决定了哪一台机器;如果客户端与服务器在同一台机器里时,这个数字是 0,或者说 ND\_LOCAL\_NODE; pid 是服备器的进程号; 而 chid 就是服务器调用 ChannelCreate()后得到的频道号了。Index 与 Flag 以后再讨论。基本上客户端就是同 " Node 这台机器里的,Pid 这个进程的,Chid 频道 " 做一个连接。有了连接以后,就可以进行消息传递了。

连接的终止是 ConnectDetach(),而频道的结束则是 ChannelDestroy()了。不过,一般服务器都是长久存在的,不大有需要 ChannelDestroy()的时候。

# 发送(Send),接收(Receive)和应答(Reply)

QNX 的消息传递,与我们传统常见的进程间通讯最大的不同,就是这是一个 " 同步的 " 消息传递。一个消

息传递,都要经过发送,接收和应答三个部份,所谓的 SRR 过程。这三步的每一步都会发生阻塞,这是 QNX 一个很重要也是很基本的概念。

具体来说,客户端在连接上服务器后,就可以"发送"消息;一旦发送,不论服务器端收到没有,客户端会被 阳塞。

服务器端会接收到消息,进行处理,最后,将处理结果"应答"给客户端;只有服务器"应答"了以后,客户端的 REPLY BLOCK 阻塞状态才会被解除。客户端得以继续执行"发送消息"的下一条语句。

这种同步的过程,严格保证了客户端与服务器端的时序,也大大简化了编程。具体用 API 来说,就是这样。

#### 服务器

ReceiveId = MsgReceive(Channelld, ReceiveBuffer, ReceiveBufLength, &MsgInfo); (... 检查 Buffer 里的消息进行处理 ...) MsgReply(ReceiveId, ReplyStatus, ReplyBuf, ReplyLen);

#### 客户端

MsgSend(ConnectionId, SendBuf, SendLen, ReplyBuf, ReplyLen);
(... 由 OS 将这个线程挂起 ...)
(... 当服务器 MsgReply()后,OS 解除线程的阻塞状态, 客户端可以检查自己的 ReceiveBuf 看看应答结果 ...)

服务器端在频道上进行接收,处理消息,完成后应答;客户端则是在连接上发送,要注意在发送的同时,客户端还同时已经提供了接收应答用的缓冲。

如果你细心的话,或许你会问,服务器端的 MsgReceive()与客户端的 MsgSend()没有同步,会不会有问题呢? 比如,如果 MsgSend()时,服务器没有在 MsgReceive(),会出什么事呢?答案是 OS 依然会把发送线程挂起,发送线程从执行状态(RUNNING)转入"发送阻塞"状态(SEND BLOCK),一直等到服务器来MsgReceive()时,再将 SendBuf 里的东西复制到 ReceiveBuffer 里去,同时发送线程的状态变成"应答阻塞"(REPLY BLOCK)。在 QNX 上用 pidin 查看进程、线程状态时,可以看到很多线程在 REPLY 状态下,就是这个原因。说明该线程向服务器发送了消息,但还没有得到应答。在 QNX 里这是非常常见的情况,比如你去 read()一个串口,串口驱动就是你的服务器,当没有数据进来时,串口驱动就不应答你,造成你的程序一直在 read() 里等着。

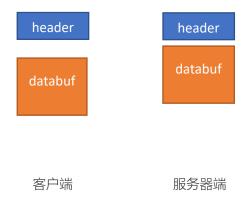
一般不太容易看到 SEND BLOCK 的线程,因为这意味着服务器已经不能正常提供服务了。

同样的,如果服务器调用 MsgReceive()时,没有客户端,服务器线程也会被挂起,进入"接收阻塞"状态 (RECEIVE BLOCK)。这个也可以在 pidin 里经常看到。

在应答时,还可以用 MsgError()来告诉发送方有错误发生了。因为 MsgReply()也可以返回一个状态,或许你会问这两者之间有什么区别? MsgReply(rcvid, EINVAL, 0, 0);的结果是,MsgSend() 这个函数的返回值是22(EINVAL);而 MsgError(rcvid, EINVAL);的结果,是 MsgSend()返回-1,而 errno 被设为 EINVAL。

### 数据区与 iov

除了用线性的缓冲区进行消息传递以外,为了方便使用,QNX 还提供了用 iov\_t 来"汇集"数据。也就是说,可以一次传送几块数据。好象下面的图这样子。虽然在客户端蓝色的 Header 同红色的 databuf 是两块不相邻的内存,但传递到服务器端的 ReceiveBuffer 里,就是连续的了。也就是说在服务器端,要想得到原来databuf 里的数据,只需要(ReceiveBuffer + sizeof(header))就可以了。(要注意数据结构对齐)



### 客户端

SETIOV(&iov[0], &header, sizeof(header)); SETIOV(&iov[1], databuf, datalen); MsgSendvs(ConnectionId, iov, 2, Replybf, ReplyLen);

"header" 与 "databuf" 是不连续的两块数据。

服务器接收后,"header"与"databuf"被连续地存在 ReceiveBuffer 里。

ReceiveId = MsgReceive(Channelld, ReceiveBuffer, ReceiveBufLength, &MsgInfo);

header = (struct header \*)ReceiveBUffer; databuf = (char \*)((char \*)header + sizeof(\*header));

### 例子

好了,有了以上这些基本函数(内核调用),我们就可以写一个客户端和一个服务器端,进行最基本的通信了。

服务器:这个服务器,准备好频道后,就从频道上接收信息。如果信息是字符串"Hello"的话,这个服务器应答一个"World"字符串。如果收到的信处是字符串"Ni Hao",那么它会应答"Zhong Guo",其它任何消息都用 MsgError()回答一个错误。

```
$ cat simple server.c
// Simple server
#include <errno.h>
#include <stdio.h>
#include <string.h>
#include <sys/neutrino.h>
int main()
     int chid, rcvid, status;
     char buf[128];
     if ((chid = ChannelCreate(0)) == -1) {
          perror("ChannelCreate");
          return -1;
     printf("Server is ready, pid = %d, chid = %d\n", getpid(), chid);
     for (;;) {
           if ((rcvid = MsgReceive(chid, buf, sizeof(buf), NULL)) == -1) {
                perror("MsgReceive");
                return -1;
          printf("Server: Received '%s'\n", buf);
          /* Based on what we receive, return some message */
          if (strcmp(buf, "Hello") == 0) {
                MsgReply(rcvid, 0, "World", strlen("World") + 1);
          } else if (strcmp(buf, "Ni Hao") == 0) {
```

客户端:客户端通过从命令行得到的服务器的进程号与频道号,与服务器建立连接。然后向服务器发送三遍"Hello"和"Ni Hao",并检查返回值。最后发一个"unknown"看是不是 MsgSend()会得到一个出错返回。

```
$ cat simple client.c
//simple client
#include <stdio.h>
#include <string.h>
#include <sys/neutrino.h>
int main(int argc, char **argv)
     pid t spid;
     int chid, coid, i;
     char buf[128];
     if (argc < 3) {
           fprintf(stderr, "Usage: simple client <pid> <chid> \n");
           return -1;
     spid = atoi(argv[1]);
     chid = atoi(argv[2]);
     if ((coid = ConnectAttach(0, spid, chid, 0, 0)) == -1) {
           perror("ConnectAttach");
           return -1;
     /* sent 3 pairs of "Hello" and "Ni Hao" */
     for (i = 0; i < 3; i++) {
```

```
sprintf(buf, "Hello");
     printf("client: sent '%s'\n", buf);
     if (MsgSend(coid, buf, strlen(buf) + 1, buf, sizeof(buf)) != 0) {
           perror("MsgSend");
           return -1;
     printf("client: returned '%s'\n", buf);
     sprintf(buf, "Ni Hao");
     printf("client: sent '%s'\n", buf);
     if (MsgSend(coid, buf, strlen(buf) + 1, buf, sizeof(buf)) != 0) {
           perror("MsgSend");
           return -1;
     printf("client: returned '%s'\n", buf);
/* sent a bad message, see if we get an error */
sprintf(buf, "Unknown");
printf("client: sent '%s'\n", buf);
if (MsgSend(coid, buf, strlen(buf) + 1, buf, sizeof(buf)) != 0) {
     perror("MsgSend");
     return -1;
ConnectDetach(coid);
return 0;
```

### 分别编译后的执行结果是这样的:

### 服务器:

```
$ ./simple_server

Server is ready, pid = 36409378, chid = 2

Server: Received 'Hello'

Server: Received 'Ni Hao'

Server: Received 'Unknown'
```

#### 客户端:

\$./simple\_client 36409378 2
client: sent 'Hello'
client: returned 'World'
client: sent 'Ni Hao'
client: returned 'Zhong Guo'
client: sent 'Hello'
client: returned 'World'
client: returned 'Zhong Guo'
client: returned 'Zhong Guo'
client: returned 'World'
client: returned 'World'
client: returned 'World'
client: returned 'Zhong Guo'
client: sent 'Ni Hao'
client: returned 'Zhong Guo'
client: sent 'Unknown'
MsgSend: Invalid argument

### 可变消息长度

从上面的程序也可以看出来,消息传递的实质是把数据从一个缓冲,复制到(另一个进程的)另一个缓冲 里去。问题是,如何确定缓冲的大小呢?上述的例子里,服务器端用了一个 128 字节的缓冲,万一客户端 发送一个比如说 512 字节的消息,是不是消息传递就会出错了呢?

答案是,消息传递依然成功,但是,只有 SendBuffer 的最初的 128 个字节的数据会被复制。这个设计背后的思想是,服务器预先是不可能知道客户端要发多少数据的,所以它一定需要正确地发现这样的情形,并设法取得完整的数据。

在 MsgRecieve()时,第四个参数是一个 struct \_msg\_info。内核会在进行消息传递的同时,填充这个结构,从而告诉让你得到一些信息。在这个结构中,"msglen"告诉你这次消息传递你实际收到了多少字节(在我们的例子里,就是 128),而"srcmsglen"则告诉你发送方的实际 Buffer 会有多大(在我们的例子里,是512)。通过比较这两个值,服务器端就可以判断有没有收到全部数据。

一旦服务器知道了还有更多的数据没有收到,那该怎么办呢? QNX 提供了 MsgRead()这个特殊函数。服务器端可以用这个函数,从发送缓冲中"读取"数据。MsgRead()基本上就是告诉内核,从发送缓冲的某个指定偏移开始,读取一定长的数据回来。所以服务器端这部份的代码基本上是这样的。

```
int rcvid;
struct msg info info;
char buf[128], *totalmsg;
rcvid = MsgReceive(chid, buf, 128, &info);
if (info->srcmsglen > info->msglen) {
  totalmsg = malloc(info->srcmsglen);
  if (!totalmsg) {
     MsgError(rcvid, ENOMEM);
     continue;
  }
  memcpy(totalmsg, buf, 128);
  if (MsgRead(rcvid, &totalmsg[128], 128, info->srcmsglen - info->msglen) == -1) {
     MsgError(rcvid, EINVAL);
     continue:
  }
} else {
  totalmsg = buf;
}
/* Now totalmsg point to a full message, don't forget to free() it later on,
 * if totalmsg is malloc()'d here
 */
```

你或者会问,为什么服务器都已经接收数据了,怎么还能再去读取客户端的数据?这是因为从一开始我们就提到的,QNX的消息传递是"同步"的。还记得吗?在服务器端"应答"之前,客户端是被阻塞的;也说是说客户端的发送缓冲会一直保留在那里,不会变化。(另外再开个线程去把这个缓冲搞乱甚至 free 掉?当然可以。不过,这是你客户端程序的 BUG 了)

与此相近的,有的时候,服务器需要返回大量的数据给客户端(比如说 1M)。服务器不希望 malloc(1024 \* 1024),然后 MsgReply(),然后再 free()。 (在嵌入式程序里,经常地进行 malloc()/free()不是一个很好的习惯) 那么服务器也可以用一个小的定长缓冲,比方说 16K,然后把数据"一部份一部份地写回"客户端的应答缓冲里。好象下面的样子。要记得最后还是要做一个 MsgReply() 以让客户端继续运行。

```
char *buf[16 * 1024];
unsigned offset;
```

```
for (offset = 0; offset < 1024 * 1024; offset += 16 * 1024) {
    /* moving data into buffer */
    MsgWrite(rcvid, buffer, 16 * 1024, offset);
}
/* 1MB returned, Reply() to let client go */
MsgReply(rcvid, 0, 0, 0,);
```

### 实例

QNX 公司大约在 2007 年时,在网上公布过包括内核、C 库和大量系统应用的源码。以下是 QNX 的 C 库中的 read()和 write()函数实装,有了前面的基础,应该很好理解了。

先不管 fd 是如何得到的,只要理解 fd 就是 ConnectAttach()返回的连接号就可以了。虽然 read()是从服务器取得数据,而 write()是向服务器输出数据,但实质上,它们都是向服务器提出一个请求,由服务器来应答。而对于 write()来说,这是一个 io\_write\_t,一个 MsgWritev()把请求与要传递的数据一起发给服务器;而对于 read()来说,请求被封装在 io\_read\_t 里,MsgSend()把这请求传给服务器,read()的结果缓冲,则做为应答缓冲,由服务器 MsgReply()时填入。

read():

```
* $QNXLicenseC:

* Copyright 2007, QNX Software Systems. All Rights Reserved.

* You must obtain a written license from and pay applicable license fees to QNX

* Software Systems before you may reproduce, modify or distribute this software,

* or any work that includes all or part of this software. Free development

* licenses are available for evaluation and non-commercial purposes. For more

* information visit http://licensing.qnx.com or email licensing@qnx.com.

*

* This file may contain contributions from others. Please review this entire

* file for other proprietary rights or license notices, as well as the QNX

* Development Suite License Guide at http://licensing.qnx.com/license-guide/

* for other information.

* $

*/
```

```
#include <unistd.h>
         #include <sys/iomsg.h>
         ssize t read(int fd, void *buff, size t nbytes) {
                  io read t
                                   msg;
                  msg.i.type = IO READ;
                  msg.i.combine len = sizeof msg.i;
                  msg.i.nbytes = nbytes;
                  msg.i.xtype = IO XTYPE NONE;
                  msg.i.zero = 0;
                 return MsgSend(fd, &msg.i, sizeof msg.i, buff, nbytes);
write():
          * $QNXLicenseC:
          * Copyright 2007, QNX Software Systems. All Rights Reserved.
          * You must obtain a written license from and pay applicable license fees to QNX
          * Software Systems before you may reproduce, modify or distribute this software,
          * or any work that includes all or part of this software. Free development
          * licenses are available for evaluation and non-commercial purposes. For more
          * information visit http://licensing.qnx.com or email licensing@qnx.com.
          * This file may contain contributions from others. Please review this entire
          * file for other proprietary rights or license notices, as well as the QNX
          * Development Suite License Guide at http://licensing.qnx.com/license-guide/
          * for other information.
          * $
          */
         #include <unistd.h>
         #include <sys/iomsg.h>
         ssize t write(int fd, const void *buff, size t nbytes) {
```

```
io_write_t msg;
iov_t iov[2];

msg.i.type = _IO_WRITE;
msg.i.combine_len = sizeof msg.i;
msg.i.xtype = _IO_XTYPE_NONE;
msg.i.nbytes = nbytes;
msg.i.zero = 0;
SETIOV(iov + 0, &msg.i, sizeof msg.i);
SETIOV(iov + 1, buff, nbytes);
return MsgSendv(fd, iov, 2, 0, 0);
}
```

服务器端应该是怎样进行处理的?想想 MsgRead()/MsgWrite(),你应该不难想像服务器端是如何工作的吧。

另外可以看到,"消息发送一直阻塞到收到数据"这个特性,很好地符合了 Posix 关于 read()/write()一直阻塞到函数完成的定义。你调用 read(),等函数返回时,要么正确地读到了数据,要么出错了,对吧。

### 脉冲(Pulse)

脉冲其实更像一个短消息,也是在"连接"上发送的。脉冲最大的特点是它是异步的。发送方不必要等接收方应答,直接可以继续执行。但是,这种异步性也给脉冲带来了限制。脉冲能携带的数据量有限,只有一个8位的"code"域用来区分不同的脉冲,和一个32位的"value"域来携带数据。脉冲最主要的用途就是用来进行"通知"(Notification)。不仅是用户程序,有时候内核也会生成特殊的"系统脉冲"发送到用户程序,以通知某一特殊情况的发生。

脉冲的接收比较简单,如果你有一个频道只接受脉冲的话,可以用 MsgReceivePulse()来接收脉冲;如果频道既可以接收消息,也可以接收脉冲时,就直接用 MsgReceive(),只要确保接收缓冲(ReveiveBuf)至少可以容下一个脉冲(sizeof struct \_pulse)就可以了。在后一种情况下,如果 MsgReceive()返回的 rcvid 是 0,就代表接收到了一个脉冲,反之,则收到了一个消息。所以,一个既接收脉冲,又接收消息的服务器,可以是这样的。

```
union {
    struct _pulse pulse;
    msg_header header;
} msgs;
...
if ((rcvid = MsgReceive(chid, &msgs, sizeof(msgs), &info)) == -1) {
    perror("MsgReceive");
```

```
continue;
}

if (rcvid == 0) {
    process_pulse(&msgs, &info);
} else {
    process_message(&msgs, &info);
}
```

脉冲的发送,最直接的就是 MsgSendPulse()。不过,这个函数一般不太会直接用到。比较可能的用法是在一个进程中,有一个线程要通知另一个服务器线程什么事情的情形。在更多的时候,以及跨进程的时候,通常不会用到这个函数,而是用到下面将要提到的 MsgDeliverEvent()。

与消息传递相比,消息传递永远是在用户进程间进行的。也就是说,不会有内核向某一个进程发送数据的情形。而脉冲就不一样,除了用户进程间可以发脉冲以外,内核也会向用户进程发送"系统脉冲"来通知某一事件的发生。

## 消息传递的方向与 MsgDeliverEvent()

从一开始就提到,QNX 的消息传递是客户端、服务器型的。也就是说,总是由客户端向服务器端发送请求,等待被回复的。但在现实情况中,客户端与服务器端并不是很容易区分开来的。有的服务器端为了处理客户端的请求,本身就需要向别的服务器发送消息;有的客户端需要从不同的服务器那里得到服务,而不能阻塞在某一特定的服务器上;还有的时候,两个进程间的数据是互相流动的,这应该怎么办呢?

也许有人认为,两个进程互为通讯就可以了。每个进程都建立自己的频道,然后都与对方的频道建一个连接就好了;这样,需要的时候,就可以直接通过连接向对方发送消息了。就好象管道(pipe)或是 socketpair 一样。请注意,这种设计在 QNX 的消息传递中是应该避免的。因为很容易就造成死锁。一个常见的情形是这样的。

进程 A: MsgSend() 到进程 B

进程 B: MsgReceive()接收到消息

进程 B:处理消息,然后 MsgSend()给进程 A

因为进程 A 正在阻塞状态中,无法接收并处理 B 的请求;所以 A 会在 REPLY\_BLOCK 里,而 B 则会因 MsgSend()但无人接收数据而进入 SEND BLOCK,两个进程就互为死锁住了。当然,如果 A 和 B 都使用多

线程,专门用一个线程来 MsgReceive(),这个情形或许可以避免;但你要保证 MsgReceive()的线程不会去 MsgSend(),否则一样会死锁。在程序简单的时候或许你还有控制,如果程序变得复杂,又或者你写的只是一个程序库,别人怎么来用你完全没有控制,那么最好还是不要用这种设计。

在 QNX 中, 正确的方法是这样的。

客户端: 准备一个"通知事件"(Notification Event),并把这个事件用 MsgSend()发给服务器端,意思是: "如果 xxx 情况发生的话,请用这个事件通知我"。

服务器: 收到这个消息后,记录下当时的 rcvid,和传过来的事件,然后应答"好的,知道了"。

客户端: 因为有了服务器的应答, 客户端不再阻塞, 可以去做别的事

....

服务器: 在某个时刻,客户端所要求的"xxx 情况"满足了,服务器调用 MsgDeliverEvent(rcvid, event);以通

知客户端

客户端: 收到通知,再用 MsgSend()发关"xxx 情况的数据在哪里?"

服务器: 用 MsgReply()把数据返回给客户端

具体的例子,可以参考 MsgDeliverEvent()的文档说明。

## 路径名 (Path Name)

现在来回想一下我们最初的例子,客户端与服务器是怎样取得连接的?客户端需要服务器的 nd, pid, chid, 才能与服务器正确地建立连接。在我们的例子里,我们是让服务器显示这几个数,然后在客户端的启动时,通过命令行里传给客户端。但是,在一个现实的系统里,进程不断地启动、终止;服务器与客户端的起动过程也无法控制,这种方法显然是行不通的。

QNX 的解决办法,是把"路径名"与上述的"服务频道"概念巧妙地结合起来。让服务器进程可以注册一个路径名,与服务频道的 nd, pid, chid 关联起来。这样,客户端就不需要知道服务器的 nd, pid, chid,而只要请求连接版务器路径名就可以了。具体来说 name\_attach()就是用来建立一个频道,并为频道注册一个名字的;而 name\_open()则是用来连接注册过的服务器频道;具体的例子,可以在 name\_attach()的文档里找到,这里就不再重复了。

除了 name\_attach()/name\_open(),在资源管理器时还会讲到资源管理器是如何获取路径名的。同时路径名 (在资源管理器时也称做命名空间 name space) 或者说命名空间的管理, 水也相当地深。有机会再另开章节讨论吧。